2022학년도 1학기 컴퓨터언어학

제10강 신경망 언어 모형 (4)

박수지

서울대학교 인문대학 언어학과

2022년 4월 6일 수요일

오늘의 목표

1. 순방향신경망 학습에 필요한 손실함수를 도출할 수 있다.
2. 합성함수의 계산 그래프를 그리고 순전파를 수행할 수 있다.
3. 순방향신경망을 이루는 각 계층의 미분값을 역방향으로 구하는 오차역전파법을 설명할 수 있다.

손실함수

로지스틱 회귀분석(이항 분류)의 교차엔트로피 손실함수

$$\begin{aligned} L_{CE}(\hat{y}, y) &= -\log p(y|\vec{x}) && \cdots \text{교차엔트로피 손실함수의 정의.} \\ &= -\left[y \log \hat{y} + (1-y) \log (1-\hat{y})\right] && \cdots \text{3강 슬라이드 22–23면 참조.} \end{aligned}$$

일반화($\rightarrow$ 다항 분류)

스칼라 $y \in \{0,1\}$를 원-핫 인코딩 벡터 $\vec{y} = [y_1, y_2] \in \{0,1\}^2$로 표현할 수 있다.

정답 표상

1. $y = 1 \;\Rightarrow\; y_1 = 1 \;\Rightarrow\; \vec{y} = [1,0]$
2. $y = 0 \;\Rightarrow\; y_2 = 1 \;\Rightarrow\; \vec{y} = [0,1]$

추정치

1. $\hat{y} = P(y = 1|\vec{x}) \;\Rightarrow\; \hat{y}_1 = P(y_1 = 1|\vec{x})$
2. $1 - \hat{y} = P(y = 0|\vec{x}) \;\Rightarrow\; \hat{y}_2 = P(y_2 = 1|\vec{x})$

손실함수

로지스틱 회귀분석(이항 분류)의 교차엔트로피 손실함수

$$L_{CE}\left(\hat{y}, y\right) = -\left[y \log \hat{y} + (1-y) \log\left(1-\hat{y}\right)\right]$$

소프트맥스 회귀분석(다항 분류)의 교차엔트로피 손실함수

부류가 K개 있을 때

$K = 2$ $L_{CE}\left(\hat{\vec{y}}, \vec{y}\right) = -\left[y_1 \log \hat{y}_1 + y_2 \log \hat{y}_2\right]$

$K = 3$ $L_{CE}\left(\hat{\vec{y}}, \vec{y}\right) = -\left[y_1 \log \hat{y}_1 + y_2 \log \hat{y}_2 + y_3 \log \hat{y}_3\right]$

$\cdots$ $L_{CE}\left(\hat{\vec{y}}, \vec{y}\right) = -\sum_{k=1}^{K} y_k \log \hat{y}_k$

손실함수

소프트맥스 회귀분석(다항 분류)의 교차엔트로피 손실함수

$$
\begin{aligned}
L_{CE}\left(\hat{\vec{y}}, \vec{y}\right) &= -\sum_{k=1}^{K} y_k \log \hat{y}_k \\
&= -\log \hat{y}_c \qquad \text{(c가 정답인 경우)}
\end{aligned}
$$

관찰

두 번째 등식이 성립하는 이유

- $\vec{y}$가 원-핫 인코딩 벡터이므로, $\vec{x}$의 정답이 c번째 부류일 때 $y_c = 1$이다.
- $k \neq c$인 k의 경우 $y_k = 0$이므로 $y_k \log \hat{y}_k = 0$이 된다.

손실함수

소프트맥스 회귀분석(다항 분류)의 매개변수

n차원 입력 벡터 $\vec{x} = [x_1, x_2, \cdots, x_n]^T$를 K개 중 하나의 부류로 분류할 때

가중치 행렬 $\mathbf{W} = \begin{bmatrix} \vec{w}_1 \\ \vec{w}_2 \\ \vdots \\ \vec{w}_K \end{bmatrix} = \begin{bmatrix} w_{1,1} & w_{1,2} & \cdots & w_{1,n} \\ w_{2,1} & w_{2,2} & \cdots & w_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ w_{K,1} & w_{K,2} & \cdots & w_{K,n} \end{bmatrix}$

편향 벡터 $\vec{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_K \end{bmatrix}$

손실함수

예시: 소프트맥스 회귀분석의 매개변수

4차원 입력 벡터 $\vec{x} = [x_1, x_2, x_3, x_4]^\intercal$를
3개 중 하나의 부류로 분류할 때

$$\mathbf{W} = \begin{bmatrix} \vec{w}_1 \\ \vec{w}_2 \\ \vec{w}_3 \end{bmatrix} = \begin{bmatrix} w_{1,1} & w_{1,2} & w_{1,3} & w_{1,4} \\ w_{2,1} & w_{2,2} & w_{2,3} & w_{2,4} \\ w_{3,1} & w_{3,2} & w_{3,3} & w_{3,4} \end{bmatrix}$$

$$\vec{b} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

가중합과 확률 추정치

$$\vec{z} = \mathbf{W}\vec{x} + \vec{b} = \begin{bmatrix} \vec{w}_1 \cdot \vec{x} + b_1 \\ \vec{w}_2 \cdot \vec{x} + b_2 \\ \vec{w}_3 \cdot \vec{x} + b_3 \end{bmatrix}$$

$$\hat{\vec{y}} = \begin{bmatrix} \text{softmax}(z_1) \\ \text{softmax}(z_2) \\ \text{softmax}(z_3) \end{bmatrix} = \begin{bmatrix} \frac{\exp(z_1)}{\sum_{k=1}^{3} \exp(z_k)} \\ \frac{\exp(z_2)}{\sum_{k=1}^{3} \exp(z_k)} \\ \frac{\exp(z_3)}{\sum_{k=1}^{3} \exp(z_k)} \end{bmatrix}$$

손실함수

소프트맥스 회귀분석(다항 분류)의 교차엔트로피 손실함수

$$
\begin{aligned}
L_{CE}\left(\hat{\vec{y}}, \vec{y}\right) &= -\log \hat{y}_c \quad (c\text{가 정답인 경우}) \\
&= -\log \operatorname{softmax}\left(z_c\right) \\
&= -\log \frac{\exp(z_c)}{\sum_{k=1}^{K} \exp(z_k)} \\
&= -\log \frac{\exp\left(\vec{w}_c \cdot \vec{x} + b_c\right)}{\sum_{j=1}^{K} \exp\left(\vec{w}_j \cdot \vec{x} + b_j\right)}
\end{aligned}
$$

기울기 계산하기

목표

손실함수 L_{CE}의 값을 최소로 하는 매개변수 $\mathbf{W}, \vec{b}$의 값을 찾는다.

필요한 것

각 매개변수에 대한 편도함숫값 $\frac{\partial L_{CE}}{\partial w_{k,i}}$

로지스틱 회귀분석에서 손실함수의 편도함수

$$\frac{\partial L_{CE}}{\partial w_j} = (\hat{y} - y)x_j \quad (j = 1, 2, \cdots, n)$$

기울기 계산하기

신경망의 마지막 계층(출력층)…

입력층 $\vec{x} = [x_1, x_2, \cdots, x_n] \in \mathbb{R}^n$

가중합 $\vec{z} = \mathbf{W}\vec{x} + \vec{b} \in \mathbb{R}^K$

출력층 $\hat{\vec{y}} = \text{softmax}(\vec{z}) \in \mathbb{R}^K$

$$\mathbf{W} = \begin{bmatrix} \vec{w}_1 \\ \vec{w}_2 \\ \vdots \\ \vec{w}_K \end{bmatrix} = \begin{bmatrix} w_{1,1} & w_{1,2} & \cdots & w_{1,n} \\ w_{2,1} & w_{2,2} & \cdots & w_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ w_{K,1} & w_{K,2} & \cdots & w_{K,n} \end{bmatrix}$$

…에서 손실함수의 편도함수

$$\begin{aligned} \frac{\partial L_{CE}}{\partial w_{k,i}} &= (\hat{y}_k - y_k)\, x_i \\ &= -(y_k - \hat{y}_k)\, x_i \\ &= -\left(y_k - \frac{\exp(\vec{w}_k \cdot \vec{x} + b_k)}{\sum_{j=1}^{K} \exp(\vec{w}_j \cdot \vec{x} + b_j)} \right) x_i \end{aligned}$$

문제

출력층 이전의 은닉층에는 적용할 수 없다!

계산 그래프

계산 그래프

계산을 여러 연산으로 쪼개어 각 연산을 노드로 표현한 그래프

예시: 순전파

$L(a, b, c) = c(a + 2b)$
이 함수를 쪼개어 보자.

$$d = 2b$$
$$e = a + d$$
$$L = ce$$

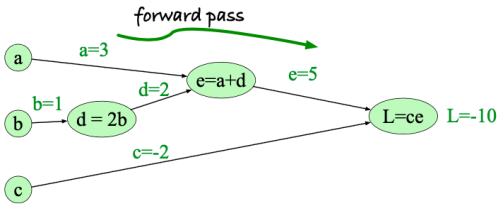

Figure 7.14 Computation graph for the function $L(a, b, c) = c(a+2b)$, with values for input nodes $a = 3$, $b = 1$, $c = -2$, showing the forward pass computation of L.

계산 그래프에서의 역방향 미분

미분의 연쇄법칙

합성함수의 미분 $f(x) = u(v(x)) \quad \Rightarrow \quad \frac{df}{dx} = \frac{du}{dv} \times \frac{dv}{dx}$

예시: 역전파

$L(a, b, c) = c(a + 2b) = c(a + d) = ce$

$$\frac{\partial L}{\partial d} = \frac{\partial L}{\partial e}\frac{\partial e}{\partial d} = \frac{\partial}{\partial e}(ce) \times \frac{\partial}{\partial d}(a + d)$$

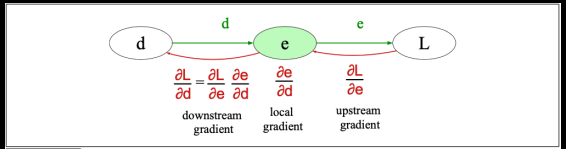

Figure 7.15 Each node (like *e* here) takes an upstream gradient, multiplies it by the local gradient (the gradient of its output with respect to its input), and uses the chain rule to compute a downstream gradient to be passed on to a prior node. A node may have multiple local gradients if it has multiple inputs.

계산 그래프에서의 역방향 미분

예시: 역전파

$$
\begin{aligned}
L(a,b,c) &= c(a+2b) \\
&= c(a+d) \\
&= ce
\end{aligned}
$$

$$
\begin{aligned}
\frac{\partial L}{\partial a} &= \frac{\partial L}{\partial e}\frac{\partial e}{\partial a} \\
\frac{\partial L}{\partial b} &= \frac{\partial L}{\partial e}\frac{\partial e}{\partial d}\frac{\partial d}{\partial b} \\
\frac{\partial L}{\partial c}
\end{aligned}
$$

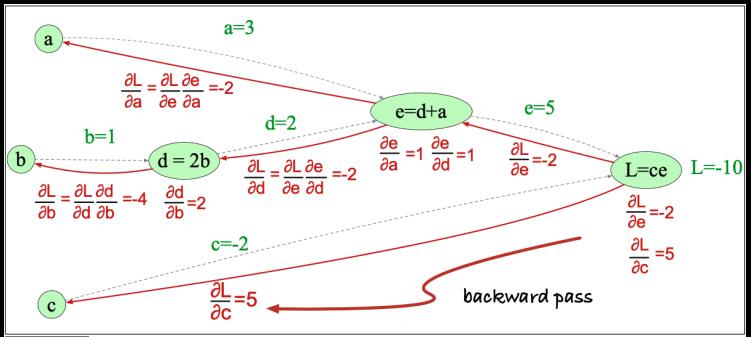

Figure 7.16 Computation graph for the function $L(a,b,c) = c(a+2b)$, showing the backward pass computation of $\frac{\partial L}{\partial a}$, $\frac{\partial L}{\partial b}$, and $\frac{\partial L}{\partial c}$.

계산 그래프에서의 역방향 미분

로지스틱 함수의 계산 그래프 그려 보기

로지스틱 함수

$$\sigma(z) = \frac{1}{1+\exp(-z)}$$

$$a = -z$$
$$b = \exp(a)$$
$$c = 1 + b$$
$$\sigma = \frac{1}{c}$$

$$\frac{d\sigma}{dz} = \frac{d\sigma}{dc}\frac{dc}{db}\frac{db}{da}\frac{da}{dz}$$

$$\frac{da}{dz} = -1$$
$$\frac{db}{da} = \exp(a) = b$$
$$\frac{dc}{db} = 1$$
$$\frac{d\sigma}{dc} = -\frac{1}{c^2}$$

계산 그래프에서의 역방향 미분

로지스틱 함수의 미분

로지스틱 함수…

$$\sigma(z) = \frac{1}{1+\exp(-z)}$$

$$a = -z$$
$$b = \exp(a)$$
$$c = 1 + b$$
$$\sigma = \frac{1}{c}$$

$$\frac{da}{dz} = -1$$
$$\frac{db}{da} = \exp(a) = b$$
$$\frac{dc}{db} = 1$$
$$\frac{d\sigma}{dc} = -\frac{1}{c^2}$$

…의 도함수 구하기

$$\begin{aligned}\frac{d\sigma}{dz} &= \frac{d\sigma}{dc} \times \frac{dc}{db} \times \frac{db}{da} \times \frac{da}{dz} \\ &= \left(-\frac{1}{c^2}\right) \times 1 \times b \times (-1) \\ &= \frac{b}{c^2} \\ &= \frac{\exp(-z)}{[1+\exp(-z)]^2}\end{aligned}$$

계산 그래프에서의 역방향 미분

로지스틱 함수의 미분

로지스틱 함수의 도함수 정리하기

$$\begin{aligned}
\frac{\mathrm{d}\sigma}{\mathrm{dz}} = \frac{\mathrm{d}}{\mathrm{dz}}\left[\frac{1}{1+\exp(-\mathrm{z})}\right] &= \frac{\exp(-\mathrm{z})}{[1+\exp(-\mathrm{z})]^2} \\
&= \frac{1}{1+\exp(-\mathrm{z})} \times \frac{\exp(-\mathrm{z})}{1+\exp(-\mathrm{z})} \\
&= \frac{1}{1+\exp(-\mathrm{z})} \times \frac{1+\exp(-\mathrm{z})-1}{1+\exp(-\mathrm{z})} \\
&= \frac{1}{1+\exp(-\mathrm{z})} \times \left[\frac{1+\exp(-\mathrm{z})}{1+\exp(-\mathrm{z})} - \frac{1}{1+\exp(-\mathrm{z})}\right] \\
&= \sigma(1-\sigma)
\end{aligned}$$

계산 그래프에서의 역방향 미분

2층 신경망의 손실함수를 1층 매개변수로 편미분하기

입력값 $\vec{x} = [x_1, x_2] \in \mathbb{R}^2$

가중합1 $\vec{z}^{[1]} = \mathbf{W}^{[1]}\vec{x} + \vec{b}^{[1]} \in \mathbb{R}^2$

1. $z_1^{[1]} = w_{1,1}^{[1]} x_1 + w_{1,2}^{[1]} x_2 + b_1^{[1]} \in \mathbb{R}$
2. $z_2^{[1]} = w_{2,1}^{[1]} x_1 + w_{2,2}^{[1]} x_2 + b_2^{[1]} \in \mathbb{R}$

활성홧값1 $\vec{a}^{[1]} = \text{ReLU}\left(\vec{z}^{[1]}\right) = \vec{h} \in \mathbb{R}^2$

1. $a_1^{[1]} = \text{ReLU}\left(z_1^{[1]}\right) = h_1 \in \mathbb{R}$
2. $a_2^{[1]} = \text{ReLU}\left(z_2^{[1]}\right) = h_2 \in \mathbb{R}$

가중합2 $z^{[2]} = \vec{w}^{[2]}\vec{a}^{[1]} + b^{[2]} = w_1^{[2]} a_1^{[1]} + w_2^{[2]} a_2^{[1]} + b^{[2]} \in \mathbb{R}$

활성홧값2 $a^{[2]} = \sigma\left(z^{[2]}\right) = \hat{y} \in \mathbb{R}$

손실함숫값 $L\left(a^{[2]}, y\right) = -\left[y \log a^{[2]} + (1-y) \log\left(1 - a^{[2]}\right)\right]$

계산 그래프에서의 역방향 미분

2층 신경망의 손실함수를 1층 매개변수로 편미분하기

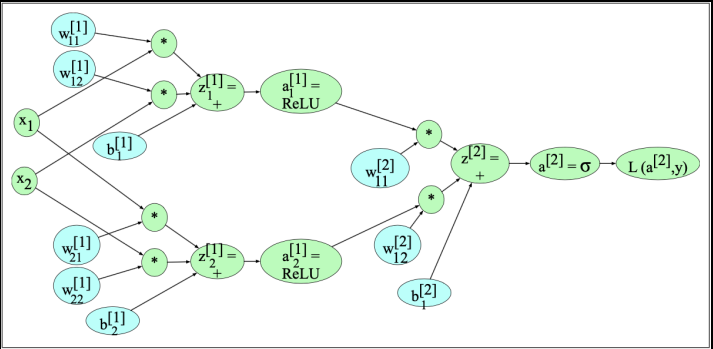

Figure 7.17 Sample computation graph for a simple 2-layer neural net (= 1 hidden layer) with two input units and 2 hidden units. We've adjusted the notation a bit to avoid long equations in the nodes by just mentioning the function that is being computed, and the resulting variable name. Thus the * to the right of node $w_{11}^{[1]}$ means that $w_{11}^{[1]}$ is to be multiplied by x_1, and the node $z^{[1]} = +$ means that the value of $z^{[1]}$ is computed by summing the three nodes that feed into it (the two products, and the bias term $b_i^{[1]}$).

계산 그래프에서의 역방향 미분

2층 신경망의 손실함수를 1층 매개변수로 편미분하기

손실함수의 편도함수: 연쇄법칙

$$\frac{\partial \mathsf{L}}{\partial \mathsf{w}_{1,1}^{[1]}} = \frac{\partial \mathsf{L}}{\partial \mathsf{a}^{[2]}} \frac{\partial \mathsf{a}^{[2]}}{\partial \mathsf{z}^{[2]}} \frac{\partial \mathsf{z}^{[2]}}{\partial \mathsf{a}_1^{[1]}} \frac{\partial \mathsf{a}_1^{[1]}}{\partial \mathsf{z}_1^{[1]}} \frac{\partial \mathsf{z}_1^{[1]}}{\partial \mathsf{w}_{1,1}^{[1]}}$$

1. 손실함수→활성홧값2

$$\mathsf{L} = -\left[\mathsf{y} \log \mathsf{a}^{[2]} + (1-\mathsf{y}) \log\left(1-\mathsf{a}^{[2]}\right)\right]$$

$$\begin{aligned}
\frac{\partial \mathsf{L}}{\partial \mathsf{a}^{[2]}} &= -\left[\frac{\mathsf{y}}{\mathsf{a}^{[2]}} - \frac{1-\mathsf{y}}{1-\mathsf{a}^{[2]}}\right] \\
&= -\left[\frac{\mathsf{y}\left(1-\mathsf{a}^{[2]}\right) - (1-\mathsf{y})\mathsf{a}^{[2]}}{\mathsf{a}^{[2]}\left(1-\mathsf{a}^{[2]}\right)}\right] \\
&= \frac{\mathsf{a}^{[2]} - \mathsf{y}}{\mathsf{a}^{[2]}\left(1-\mathsf{a}^{[2]}\right)}
\end{aligned}$$

계산 그래프에서의 역방향 미분

2층 신경망의 손실함수를 1층 매개변수로 편미분하기

손실함수의 편도함수: 연쇄법칙

$$\frac{\partial \mathsf{L}}{\partial \mathsf{w}_{1,1}^{[1]}} = \frac{\partial \mathsf{L}}{\partial \mathsf{a}^{[2]}} \frac{\partial \mathsf{a}^{[2]}}{\partial \mathsf{z}^{[2]}} \frac{\partial \mathsf{z}^{[2]}}{\partial \mathsf{a}_1^{[1]}} \frac{\partial \mathsf{a}_1^{[1]}}{\partial \mathsf{z}_1^{[1]}} \frac{\partial \mathsf{z}_1^{[1]}}{\partial \mathsf{w}_{1,1}^{[1]}}$$

$$\frac{\partial \mathsf{L}}{\partial \mathsf{a}^{[2]}} = \frac{\mathsf{a}^{[2]} - \mathsf{y}}{\mathsf{a}^{[2]}\left(1 - \mathsf{a}^{[2]}\right)}$$

2. 활성홧값2→가중합2(로지스틱 계층)

$$\mathsf{a}^{[2]} = \sigma\left(\mathsf{z}^{[2]}\right)$$

$$\begin{aligned}\frac{\partial \mathsf{a}^{[2]}}{\partial \mathsf{z}^{[2]}} &= \sigma\left(\mathsf{z}^{[2]}\right)\left[1 - \sigma\left(\mathsf{z}^{[2]}\right)\right] \\ &= \mathsf{a}^{[2]}\left(1 - \mathsf{a}^{[2]}\right)\end{aligned}$$

계산 그래프에서의 역방향 미분

2층 신경망의 손실함수를 1층 매개변수로 편미분하기

손실함수의 편도함수: 연쇄법칙

$$\frac{\partial L}{\partial w_{1,1}^{[1]}} = \frac{\partial L}{\partial a^{[2]}} \frac{\partial a^{[2]}}{\partial z^{[2]}} \frac{\partial z^{[2]}}{\partial a_1^{[1]}} \frac{\partial a_1^{[1]}}{\partial z_1^{[1]}} \frac{\partial z_1^{[1]}}{\partial w_{1,1}^{[1]}}$$

$$\frac{\partial L}{\partial a^{[2]}} = \frac{a^{[2]} - y}{a^{[2]}\left(1 - a^{[2]}\right)}$$

$$\frac{\partial a^{[2]}}{\partial z^{[2]}} = a^{[2]}\left(1 - a^{[2]}\right)$$

3. 가중합2→활성홧값1 (Affine 계층)

$$z^{[2]} = w_1^{[2]} a_1^{[1]} + w_2^{[2]} a_2^{[1]} + b^{[2]}$$

$$\frac{\partial z^{[2]}}{\partial a_1^{[1]}} = w_1^{[2]}$$

계산 그래프에서의 역방향 미분

2층 신경망의 손실함수를 1층 매개변수로 편미분하기

손실함수의 편도함수: 연쇄법칙

$$\frac{\partial \mathsf{L}}{\partial \mathsf{w}_{1,1}^{[1]}} = \frac{\partial \mathsf{L}}{\partial \mathsf{a}^{[2]}} \frac{\partial \mathsf{a}^{[2]}}{\partial \mathsf{z}^{[2]}} \frac{\partial \mathsf{z}^{[2]}}{\partial \mathsf{a}_1^{[1]}} \frac{\partial \mathsf{a}_1^{[1]}}{\partial \mathsf{z}_1^{[1]}} \frac{\partial \mathsf{z}_1^{[1]}}{\partial \mathsf{w}_{1,1}^{[1]}}$$

$$\frac{\partial \mathsf{L}}{\partial \mathsf{a}^{[2]}} = \frac{\mathsf{a}^{[2]} - \mathsf{y}}{\mathsf{a}^{[2]}\left(1 - \mathsf{a}^{[2]}\right)}$$

$$\frac{\partial \mathsf{a}^{[2]}}{\partial \mathsf{z}^{[2]}} = \mathsf{a}^{[2]}\left(1 - \mathsf{a}^{[2]}\right)$$

$$\frac{\partial \mathsf{z}^{[2]}}{\partial \mathsf{a}_1^{[1]}} = \mathsf{w}_1^{[2]}$$

4. 활성홧값1→가중합1 (ReLU 계층)

$$\mathsf{a}_1^{[1]} = \mathsf{ReLU}\left(\mathsf{z}_1^{[1]}\right) = \begin{cases} 0, & \text{if } \mathsf{z}_1^{[1]} \leq 0 \\ \mathsf{z}_1^{[1]}, & \text{if } \mathsf{z}_1^{[1]} > 0 \end{cases}$$

$$\frac{\partial \mathsf{a}_1^{[1]}}{\partial \mathsf{z}_1^{[1]}} = \begin{cases} 0, & \text{if } \mathsf{z}_1^{[1]} \leq 0 \\ 1, & \text{if } \mathsf{z}_1^{[1]} > 0 \end{cases} = \mathbb{1}\left\{\mathsf{z}_1^{[1]} > 0\right\}$$

계산 그래프에서의 역방향 미분

2층 신경망의 손실함수를 1층 매개변수로 편미분하기

손실함수의 편도함수: 연쇄법칙

$$\frac{\partial L}{\partial w_{1,1}^{[1]}} = \frac{\partial L}{\partial a^{[2]}} \frac{\partial a^{[2]}}{\partial z^{[2]}} \frac{\partial z^{[2]}}{\partial a_1^{[1]}} \frac{\partial a_1^{[1]}}{\partial z_1^{[1]}} \frac{\partial z_1^{[1]}}{\partial w_{1,1}^{[1]}}$$

$$\frac{\partial L}{\partial a^{[2]}} = \frac{a^{[2]} - y}{a^{[2]}\left(1 - a^{[2]}\right)}$$

$$\frac{\partial a^{[2]}}{\partial z^{[2]}} = a^{[2]}\left(1 - a^{[2]}\right)$$

$$\frac{\partial z^{[2]}}{\partial a_1^{[1]}} = w_1^{[2]}$$

5. 가중합1 → 가중치1 (Affine 계층)

$$z_1^{[1]} = w_{1,1}^{[1]} x_1 + w_{1,2}^{[1]} x_2 + b_1^{[1]}$$

$$\frac{\partial z_1^{[1]}}{\partial w_{1,1}^{[1]}} = x_1$$

계산 그래프에서의 역방향 미분

2층 신경망의 손실함수를 1층 매개변수로 편미분하기

손실함수의 편도함수: 연쇄법칙

$$
\begin{aligned}
\frac{\partial \mathsf{L}}{\partial \mathsf{w}_{1,1}^{[1]}} &= \frac{\partial \mathsf{L}}{\partial \mathsf{a}^{[2]}} \frac{\partial \mathsf{a}^{[2]}}{\partial \mathsf{z}^{[2]}} \frac{\partial \mathsf{z}^{[2]}}{\partial \mathsf{a}_1^{[1]}} \frac{\partial \mathsf{a}_1^{[1]}}{\partial \mathsf{z}_1^{[1]}} \frac{\partial \mathsf{z}_1^{[1]}}{\partial \mathsf{w}_{1,1}^{[1]}} \\
&= \frac{\mathsf{a}^{[2]} - \mathsf{y}}{\mathsf{a}^{[2]}\left(1 - \mathsf{a}^{[2]}\right)} \times \mathsf{a}^{[2]}\left(1 - \mathsf{a}^{[2]}\right) \times \mathsf{w}_1^{[2]} \times \mathbb{1}\left\{\mathsf{z}_1^{[1]} > 0\right\} \times \mathsf{x}_1 \\
&= \left(\mathsf{a}^{[2]} - \mathsf{y}\right) \times \mathsf{w}_1^{[2]} \times \mathbb{1}\left\{\mathsf{z}_1^{[1]} > 0\right\} \times \mathsf{x}_1 \\
&= \begin{cases} (\hat{\mathsf{y}} - \mathsf{y})\, \mathsf{w}_1^{[2]} \mathsf{x}_1, & \text{if } \mathsf{z}_1^{[1]} > 0 \\ 0, & \text{if } \mathsf{z}_1^{[1]} \leq 0 \end{cases}
\end{aligned}
$$

계산 그래프에서의 역방향 미분

지금까지 살펴본 계층

1. 손실함수
2. 로지스틱 계층($\rightarrow$소프트맥스 계층으로 일반화 가능)
3. ReLU 계층
4. Affine 계층(가중합)

심화: tanh 계층의 역전파를 계산해 보자. (시험에 안 나옴)

관찰

위의 계층들을 조합하여 3층 이상의 신경망으로 확장할 수 있다.

남은 문제

《밑바닥부터 시작하는 딥러닝 1》 6장 〈학습 관련 기술들〉 참조 — 심화 과제

- 매개변수 갱신(최적화) 방법
- 가중치의 초깃값 설정
- 배치 정규화
- 과적합(Overfitting) 방지

다음 주에 배울 것

합성곱신경망(CNN: Convolutional Neural Networks)

- 《밑바닥부터 시작하는 딥러닝 1》 7장
- Kim (2014) “Convolutional Neural Networks for Sentence Classification” `https://arxiv.org/abs/1408.5882`